CORPORACIÓN UNIVERSITARIA DE CIENCIA Y DESARROLLO, UNICIENCIA

Programa de Ingeniería de Sistemas

Proyecto Integrador Big Data, Fase 2
Limpieza, análisis exploratorio, seguridad y optimización

Ventas semanales por tienda en una cadena de supermercados
(Walmart Recruiting - Store Sales Forecasting)

Grupo 03 · Retail / Comercio

Carlos Andrés Ávila Calao · Manuel Fernando Villamizar Palomino

Asignatura: Big Data

Docente: Ing. Jacksson Sonny Gonzalez Bayona

Bucaramanga, octubre de 2026

1. Alcance y preguntas de negocio

Esta fase construye sobre la tabla bronce de la Fase 1 y produce la capa plata, el análisis exploratorio, el tratamiento de seguridad y la medición de rendimiento. Los datos son los cuatro archivos oficiales del caso en Kaggle (train, test, features y stores): 421.570 registros de ventas de 45 tiendas y 81 departamentos entre el 5 de febrero de 2010 y el 26 de octubre de 2012 (Kaggle, s. f.). Kaggle exige iniciar sesión y aceptar las reglas de la competencia; los cuatro archivos se descargaron el 6 de septiembre de 2026 de un espejo público en GitHub (Vicky60629, s. f.) que se asume con el mismo contenido que la fuente oficial; el grupo no pudo contrastarlo directamente porque Kaggle exige sesión, aunque la estructura (45 tiendas, 81 departamentos) coincide con la descripción de la competencia. Las tres preguntas que guían el análisis son: P1, ¿cuánto suben las ventas semanales en semanas festivas, por tipo de tienda?; P2, ¿dónde se concentra la venta que hay que planear?; y P3, ¿por qué varían las ventas: clima, combustible, economía o promociones?

2. Limpieza y transformación (capa plata, A2.1)

El notebook 01_limpieza aplica seis transformaciones y registra las filas antes y después en la tabla plata_log_transformaciones. El bronce guarda todo como texto, de modo que la tipificación es una transformación real y no un efecto de la lectura.

Tabla 1

Bitácora de las seis transformaciones de la capa plata

#	Transformación	Tabla	Filas antes	Filas después	Decisión y razón
T1	Deduplicación (Store, Dept, Date)	train	421.570	421.570	No había duplicados; se deja ejecutada para comprobarlo en el workspace.
T1	Deduplicación (Store, Date)	features	8.190	8.190	Sin duplicados.
T2	Tipificación: fecha, numéricos, booleano; NA a nulo	train, features, stores	421.570 / 8.190 / 45	sin cambio	Ninguna fecha ni venta quedó sin convertir.
T3	Estandarización de Type a A/B/C	stores	45	45	Cero valores fuera del dominio.
T4	Nulos: MarkDown a 0 con bandera hay_promocion; CPI y Unemployment por arrastre	features	8.190	8.190	El nulo de MarkDown es ausencia de promoción (la primera aparece el 11-nov-2011), no error. CPI y desempleo nulos eran las últimas 13 semanas por tienda.

#	Transformación	Tabla	Filas antes	Filas después	Decisión y razón
T5	Filtrado de atípicos: ventas negativas a cuarentena	train	421.570	420.285	1.285 devoluciones superan la venta semanal; se conservan en plata_cuarentena_ventas_negativas.
T6	Unión ventas + indicadores + tiendas	plata_ventas	420.285	420.285	Unión izquierda; el conteo no cambia, sin ventas sin indicadores ni sin tienda.

3. Análisis exploratorio (A2.2)

El notebook 02_analisis contiene cinco consultas en Spark SQL. Q2 usa funciones de ventana (LAG y RANK) y Q3 une el resumen de ventas con el catálogo de tiendas, que proviene de otra fuente.

Tabla 2

Consultas, pregunta que responden e interpretación

Consulta	Pregunta	Resultado principal	Interpretación
Q1 Venta por tipo de tienda y festivo	P1	A: 20.055 a 21.333 en festivo; B: 12.203 a 13.420; C: 9.546 a 9.566	La venta sube ≈6,4 % en A y ≈10,0 % en B; en C casi no cambia. La mediana confirma la dirección en las tres.
Q2 Ventana: variación semanal y ranking (LAG, RANK)	P1	Crecimiento medio 1,78 % en semanas festivas y 0,58 % en las demás; 9 de las 10 semanas más altas son la del 24-dic-2010	El pico real de Navidad cae en una semana que IsHoliday no marca como festiva; la bandera sola subestima el riesgo de inventario.
Q3 Join ventas con tiendas; venta por departamento	P2	Ventas totales: A ≈4.331 M, B ≈2.001 M, C ≈405 M. Departamentos 92, 95 y 38: ≈19,7 % del total	Las tiendas C rinden más por unidad de tamaño (≈1.667 frente a ≈1.111 en A). Diez departamentos concentran ≈46 % de la venta.
Q4 Correlación con clima, combustible, CPI y desempleo	P3	Temperatura –0,064; combustible 0,009; CPI –0,073; desempleo –0,106	Correlaciones débiles. Al mezclar tiendas de tamaños distintos el tamaño domina; no descarta estas variables, hay que medirlas por tienda.
Q5 Intensidad de promoción × festivo (desde 11-nov-2011)	P3	Promoción alta: ≈19.300 en semana normal, ≈19.630 en festivo. Baja: ≈13.240 y ≈9.760	Desde esa fecha no hay semanas sin promoción. Es asociación, no causalidad: las promociones altas pueden concentrarse en tiendas grandes.

Nota. Cifras de la ejecución con los mismos archivos CSV; contrastar con la salida del notebook en Databricks.

4. Análisis sectorial (A2.3)

Hofmann y Rutschmann (2018) construyen un marco conceptual para aplicar analítica de datos masivos a los planes de demanda operativos, tácticos y estratégicos, y señalan que los métodos de pronóstico y las tecnologías de datos masivos se habían estudiado por separado. Ren et al. (2020) revisan métodos de pronóstico de demanda para productos de moda y los contrastan con la práctica de un minorista real, lo que los lleva a discutir los límites de los métodos tradicionales.

Coincidencias. Este caso comparte con ambos trabajos la premisa de que la planeación de inventario mejora cuando se integran fuentes externas a la historia de ventas: aquí, clima, festivos, promociones e indicadores económicos unidos por tienda y semana (T6). También coincide en que la calidad del dato condiciona el resultado: tratar mal el nulo de las promociones o las devoluciones habría cambiado las conclusiones de Q5 y Q1.

Diferencias. Ambos estudios son conceptuales o parten de moda, donde la demanda es estacional y el producto cambia cada temporada; aquí es un surtido de supermercado con 81 departamentos y una historia de 143 semanas. Además, esta fase es descriptiva: explica qué se asocia con la venta, pero todavía no pronostica; el modelo y su comparación con una línea base son de la Fase 3. Por último, los hallazgos de Q2 sobre la bandera de festivo muestran un problema de definición de variable que los marcos teóricos no abordan.

5. Seguridad y privacidad (A2.4)

El dataset es agregado por tienda, departamento y semana y no contiene datos personales (nombres, documentos, tarjetas de fidelización). La Ley 1581 de 2012 protege datos de personas naturales, de modo que no aplica directamente a estas columnas; sí hay información comercial confidencial. El notebook 03_seguridad trata los datos con niveles propios y aplica anonimización como ejercicio, porque un caso real con compras por cliente sí traería datos personales y sensibles.

Tabla 3
Clasificación de columnas por nivel de sensibilidad

Columna	Nivel	Justificación	Tratamiento
Store	Interno	Identifica un establecimiento, no una persona.	Hash SHA-256 con sal; máscara S-**
Dept	Interno	Categoría comercial interna.	Ninguno
Date	Interno	Con la tienda permite inferir la operación.	Generalizar a mes
Weekly_Sales	Confidencial	Cifra de negocio; ventaja competitiva.	Acceso por rol
Size	Interno	Con Store permite reidentificar la tienda.	Generalizar a rangos

Se aplicaron dos técnicas con antes y después: hash SHA-256 con sal sobre Store (la tabla plata_ventas_anonimizadas no contiene Store ni Date en claro) y generalización de Date a mes y de Size a rangos. El control de acceso se define por rol sobre el esquema: ingeniero_datos (lectura y escritura), analista_negocio (lectura de la tabla en claro y de la anonimizada) y auditor_externo (solo la anonimizada). Las sentencias GRANT se ejecutan sujetas a lo que permita Databricks Free Edition y el resultado queda en el notebook.

6. Comparativo de herramientas (A2.5)

Se evaluaron cuatro herramientas gratuitas autorizadas por el protocolo en cinco criterios, con escala de 1 (débil) a 3 (fuerte). La evaluación es del equipo, basada en las restricciones del proyecto y no en una prueba de rendimiento.

Tabla 4
Comparativo de herramientas de análisis y visualización

Criterio	Dashboard nativo de Databricks	Power BI Desktop	Metabase	matplotlib en notebook
Costo y licencia	3 (incluido en Free Edition)	3 (gratuito)	3 (código abierto)	3
Integración con tablas Delta	3 (lee la capa oro directo)	2 (requiere conector)	2 (requiere driver y servidor)	3
Evidencia dentro del workspace (regla de oro)	3	1 (vive fuera)	1 (vive fuera)	3
Compatibilidad con el equipo del grupo (macOS)	3 (navegador)	1 (solo Windows)	2 (Java local)	3
Interactividad y presentación	2	3	3	1
Total	14	10	11	13

Se elige el dashboard nativo de Databricks para el tablero de la Fase 3: obtiene el mayor puntaje, la evidencia queda dentro del workspace como exige el protocolo y no depende de instalar software adicional. Se complementa con matplotlib para figuras del documento.

7. Optimización (A2.6)

Se midieron tres técnicas, cada una tres veces, y se reporta la mediana en segundos. Sobre 420 mil filas el costo fijo de Spark domina, por lo que las diferencias son pequeñas y una técnica puede no mejorar; se reporta lo medido sin forzar el resultado. El caché no se usó porque el cómputo serverless de Free Edition no lo soporta.

Tabla 5

Tiempos de ejecución antes y después de cada técnica (mediana en segundos)

Técnica	Antes	Después	Tiempo antes (s)	Tiempo después (s)
1. Join	Sort-merge	Broadcast	1,24	1,20
2. Partición	Sin particionar	partitionBy(anio)	0,84	0,73
3. Z-ORDER	Sin Z-ORDER	ZORDER BY (Store)	0,77	0,76

Nota. Origen de los tiempos: ejecución del notebook 02b_optimizacion en Databricks Free Edition (serverless) el 14 de octubre de 2026, mediana de 3 ejecuciones; tabla opt_resultados_tiempos.

Lectura. El particionamiento por año redujo la mediana de 0,84 a 0,73 s (≈13 %), el broadcast join de 1,24 a 1,20 s (≈3 %) y Z-ORDER de 0,77 a 0,76 s (≈1 %). Con 420 mil filas las dos últimas mejoras están dentro del ruido: el máximo del join antes fue 2,81 s y el de Z-ORDER después, 1,62 s, por lo que una sola ejecución lenta cambia la lectura. La conclusión honesta es que a este volumen la optimización aporta poco; su valor aparecería con tablas varias órdenes de magnitud mayores.

8. Limitaciones y trabajo de la Fase 3

Las tres preguntas de negocio se derivaron de la pregunta general de la Fase 1 y pueden ajustarse. Q4 y Q5 muestran asociación, no causalidad. El dataset no permite probar el cumplimiento de la Ley 1581 con datos personales reales. La auditoría técnica cruzada (A2.7) se documenta en un acta aparte y depende del trabajo del grupo asignado. En la Fase 3 se construirán la capa oro, el tablero con seis visualizaciones, el modelo con línea base, el monitoreo y la integración.

Referencias

Hofmann, E., y Rutschmann, E. (2018). Big data analytics and demand forecasting in supply chains: A conceptual analysis. *The International Journal of Logistics Management, 29*(2), 739–766. https://doi.org/10.1108/IJLM-04-2017-0088

Kaggle. (s. f.). *Walmart Recruiting - Store Sales Forecasting* [Conjunto de datos]. https://www.kaggle.com/c/walmart-recruiting-store-sales-forecasting/data

Ley 1581 de 2012. (2012, 17 de octubre). Por la cual se dictan disposiciones generales para la protección de datos personales. Congreso de la República de Colombia.

Ren, S., Chan, H.-L., y Siqin, T. (2020). Demand forecasting in retail operations for fashionable products: Methods, practices, and real case study. *Annals of Operations Research, 291*(1), 761–777. https://doi.org/10.1007/s10479-019-03148-8

Vicky60629. (s. f.). *Walmart-Store-Sales-Forecasting* [Repositorio de GitHub]. https://github.com/vicky60629/Walmart-Store-Sales-Forecasting

Anexo. Declaración de uso de inteligencia artificial

Herramienta: Claude (Anthropic), mediante Claude Code. Tareas: redacción de los notebooks de PySpark y Spark SQL, ejecución de prueba local sobre los CSV, estructura de este informe y propuesta de las tres preguntas de negocio y del comparativo. Prompts principales: revisar el protocolo del proyecto integrador y armar la Fase 2; correr y validar los notebooks; redactar el informe. Lo que el grupo debe revisar y corregir: las cifras se obtuvieron en una ejecución local y deben contrastarse con Databricks; los resúmenes de las dos referencias se basan en sus datos bibliográficos y resúmenes, y el grupo debe leerlas completas antes de la sustentación; las puntuaciones del comparativo son criterio del equipo. La IA no tuvo acceso al workspace de Databricks ni a los repositorios de otros grupos.